

Manual: Ciência de Dados e Big Data

CRISP-DM, Machine Learning, Regressão, Classificação, Ensemble, Agrupamento, Hadoop, HDFS, MapReduce, Apache Spark e NLP

CHANCELA EDITORIAL YLUNA85 LABS

Preparação Conjunta: Auditor Fiscal (TI) & Agente de Tributos Estaduais

Revisão Ortográfica e Glossário Geral de Siglas

Material de livre circulação interna. Revisado em Português Brasileiro (pt-BR).

1. Fundamentos de Ciência de Dados, Ciclo de Vida e Metodologia CRISP-DM

A Ciência de Dados é um campo interdisciplinar que combina computação, estatística inferencial, aprendizado de máquina e conhecimento de domínio do negócio para extrair padrões complexos e valor estratégico a partir de grandes massas de dados. Na administração tributária contemporânea, a Ciência de Dados viabiliza a malha fina preditiva, a detecção de notas fiscais fraudulentas em tempo real e a seleção automatizada de contribuintes para fiscalização com base em matrizes de risco. O padrão metodológico mais cobrado em concursos públicos é o CRISP-DM (Cross-Industry Standard Process for Data Mining), um modelo cíclico estruturado em seis fases iterativas.

- As 6 Fases do CRISP-DM

1. Entendimento do Negócio (Business Understanding - definição dos objetivos de fiscalização e conversão em metas analíticas); 2. Entendimento dos Dados (Data Understanding - coleta inicial, exploração e identificação de problemas de qualidade); 3. Preparação dos Dados (Data Preparation - seleção de tabelas, limpeza, transformação e engenharia de atributos; consome de 70% a 80% do esforço do projeto); 4. Modelagem (Modeling - seleção e aplicação de algoritmos de Machine Learning); 5. Avaliação (Evaluation - validação do modelo frente aos objetivos de negócio antes do deploy); 6. Implantação (Deployment - integração aos sistemas operacionais da SEFAZ).

- Metodologias Correlatas: KDD e SEMMA

KDD (Knowledge Discovery in Databases: Seleção, Pré-processamento, Transformação, Mineração de Dados e Interpretação/Avaliação). SEMMA (metodologia do SAS Institute: Sample, Explore, Modify, Model, Assess).

- Paradigmas de Aprendizado de Máquina

Aprendizado Supervisionado (dados rotulados com variável alvo conhecida - Classificação e Regressão), Aprendizado Não Supervisionado (dados sem rótulo prévio - Agrupamento e Associação) e Aprendizado por Reforço (agente aprende por recompensas e penalidades em um ambiente dinâmico).

ALERTA DE PROVA - O CARÁTER CÍCLICO DO CRISP-DM

O CRISP-DM NÃO é um modelo linear em cascata; ele é essencialmente iterativo e cíclico. O término de uma fase pode exigir o retorno imediato a fases anteriores (ex: a fase de Modelagem frequentemente exige retornar à fase de Preparação de Dados para refazer atributos).

2. Pré-processamento, Limpeza e Engenharia de Atributos

O pré-processamento de dados constitui a etapa preparatória determinante para o sucesso dos algoritmos de aprendizado de máquina, assegurando que os dados estejam limpos, consistentes, na escala adequada e livres de redundâncias prejudiciais.

- **Tratamento de Dados Ausentes (Missing Data)**

Exclusão de Registros (aplicável apenas quando a proporção de nulos for pequena); Imputação Estatística Univariada (substituição por Média para variáveis numéricas simétricas, Mediana para variáveis assimétricas com outliers, ou Moda para variáveis categóricas); Imputação Multivariada (KNN Imputer ou algoritmos preditivos que estimam o valor faltante com base nos vizinhos mais próximos).

- **Deteção e Tratamento de Outliers**

Identificação por Z-Score (observações com $|Z| > 3$) ou pelo Intervalo Interquartil (IQR: valores abaixo de $Q_1 - 1,5 \times IQR$ ou acima de $Q_3 + 1,5 \times IQR$). Tratamento via Winsorização (limitação aos percentis extremos), transformação logarítmica ou remoção fundamentada.

- **Escalonamento de Variáveis Numéricas**

Normalização Min-Max: Redimensiona os dados para o intervalo fixo $[0, 1]$ através da fórmula $X_{\text{norm}} = \frac{X - X_{\text{min}}}{X_{\text{max}} - X_{\text{min}}}$ (sensível a outliers). Padronização Z-Score: Transforma os dados para média zero e desvio padrão unitário $Z = \frac{X - \mu}{\sigma}$ (robusta para algoritmos baseados em gradiente e distâncias como SVM, KNN e PCA).

- **Codificação de Variáveis Categóricas (Encoding)**

One-Hot Encoding: Cria uma nova coluna binária (0 ou 1) para cada categoria da variável nominal (ex: UF do destinatário), prevenindo que o modelo infira uma hierarquia falsa; Label/Ordinal Encoding: Atribui números inteiros sequenciais (1, 2, 3) para variáveis categóricas ordinais que possuem hierarquia intrínseca (ex: Porte da Empresa: Pequeno, Médio, Grande).

- **Redução de Dimensionalidade: PCA (Principal Component Analysis)**

Técnica não supervisionada de transformação linear ortogonal que projeta os dados em um novo sistema de coordenadas (Componentes Principais) alinhado às direções de máxima variância, calculadas a partir dos autovetores e autovalores da matriz de covariância. Elimina multicolinearidade e comprime centenas de colunas em poucas dimensões.

REGRA DE OURO DO ESCALONAMENTO

Algoritmos baseados em distâncias euclidianas (KNN, K-Means, SVM, PCA) e Redes Neurais EXIGEM OBRIGATORIAMENTE que as variáveis estejam na mesma escala (padronizadas). Algoritmos baseados em Árvores de Decisão (Random Forest, XGBoost) são completamente INVARIANTES à escala e não necessitam de normalização.

3. Aprendizado de Máquina Supervisionado: Regressão e Classificação

No Aprendizado Supervisionado, o modelo treina sobre um conjunto de dados composto por variáveis preditoras (Features X) e uma variável alvo conhecida (Rótulo Y). O objetivo é aprender uma função matemática de mapeamento $f(X) \rightarrow Y$ capaz de generalizar e prever corretamente o rótulo de novos dados não vistos.

- **Modelos de Regressão Linear Regularizada**

Regressão Linear Múltipla com penalização de coeficientes para evitar overfitting: 1. Ridge (Regularização L2 - adiciona a soma dos quadrados dos coeficientes $\lambda \sum \beta_j^2$, reduzindo os coeficientes próximos a zero sem anulá-los); 2. Lasso (Regularização L1 - adiciona a soma dos módulos dos coeficientes $\lambda \sum |\beta_j|$, atuando como seleção automática de variáveis ao ZERAR coeficientes irrelevantes); 3. ElasticNet (combinação linear de L1 e L2).

- **Regressão Logística**

Algoritmo de classificação binária que mapeia uma combinação linear de atributos no intervalo $[0, 1]$ através da Função Sigmóide: $P(Y=1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta X)}}$, estimando a probabilidade de um evento ocorrer (ex: probabilidade de uma nota fiscal ser fraudulenta).

- **K-Nearest Neighbors (KNN)**

Classificador não paramétrico baseado em instâncias ('Lazy Learner'). Não realiza treinamento prévio explícito; classifica uma nova observação com base no voto majoritário dos seus 'k' vizinhos mais próximos no espaço vetorial.

- **Naive Bayes**

Classificador probabilístico baseado no Teorema de Bayes com a premissa ingênua ('naive') de que todos os atributos são condicionalmente independentes entre si dado o rótulo da classe. Altamente eficiente para processamento de textos, análise de sentimentos e filtros de spam.

- **Support Vector Machines (SVM)**

Encontra o Hiperplano de Separação Ótimo que maximiza a margem de distância entre as classes no espaço vetorial. Utiliza Pontos de Suporte (Support Vectors) e a técnica do 'Kernel Trick' (kernels RBF, Polinomial e Sigmóide) para projetar dados não linearmente separáveis em espaços de dimensões superiores onde se tornam separáveis.

- **Árvores de Decisão (Decision Trees)**

Estrutura hierárquica em árvore composta por Nó Raiz, Nós Internos de decisão e Nós Folha de saída. A divisão dos nós baseia-se em critérios de pureza: Índice de Gini (algoritmo CART) ou Entropia e Ganho de Informação (algoritmos ID3 e C4.5). Modelos altamente interpretáveis pelo Fisco.

DIFERENÇA CRÍTICA: RIDGE VERSUS LASSO

Lembre-se da pegadinha clássica da FGV: A regularização Lasso (L1) realiza Seleção de Atributos porque pode ZERAR completamente os coeficientes das variáveis inúteis. A regularização Ridge (L2) apenas ENCOLHE os coeficientes para valores pequenos, mantendo todas as variáveis no modelo.

4. Algoritmos de Ensemble: Bagging, Boosting e Stacking

Os métodos de Ensemble combinam as previsões de múltiplos modelos de aprendizado de máquina individuais (Modelos Fracos / Base Learners) para produzir um modelo final preditivo com desempenho superior, maior estabilidade e menor taxa de erro.

- **Bagging (Bootstrap Aggregating) e Random Forest**

Treina múltiplos modelos independentes em paralelo sobre subconjuntos de dados gerados por amostragem aleatória com reposição (Bootstrap). A predição final resulta da média (regressão) ou votação majoritária (classificação). O Random Forest aprimora o Bagging de Árvores de Decisão ao selecionar também um subconjunto aleatório de features em cada divisão de nó, descorrelacionando as árvores e reduzindo drasticamente a VARIÂNCIA sem aumentar o viés.

- **Boosting (Treinamento Sequencial Adaptativo)**

Treina modelos fracos de forma sequencial, onde cada novo modelo foca em corrigir os erros cometidos pelos modelos anteriores, atribuindo pesos maiores às observações classificadas incorretamente. Reduz primariamente o VIÉS do modelo.

- **Algoritmos de Gradient Boosting**

1. AdaBoost (ajusta pesos de amostras); 2. GBM (Gradient Boosting Machine - otimiza uma função de perda arbitrária via gradiente descendente); 3. XGBoost (Extreme Gradient Boosting - altamente otimizado para árvores com regularização integrada e processamento paralelo); 4. LightGBM (crescimento de árvores por folhas - leaf-wise, otimizado para velocidade em grandes bases); 5. CatBoost (otimizado para variáveis categóricas nativas).

- **Stacking / Blended Models**

Arquitetura hierárquica em que as previsões geradas por múltiplos modelos de base heterogêneos (ex: SVM, Random Forest e Regressão Logística) são utilizadas como features de entrada para treinar um Meta-Classificador de nível superior.

MNEMÔNICO DE ENSEMBLE

Bagging reduz Variância (combina modelos em paralelo com dados aleatórios). Boosting reduz Viés (treina modelos em série focando nos erros).

5. Aprendizado Não Supervisionado: Agrupamento e Associação

No Aprendizado Não Supervisionado, o algoritmo opera sobre dados sem rótulos ou variáveis alvo pré-definidas, com o objetivo de descobrir estruturas intrínsecas, agrupamentos naturais e regras de correlação ocultas nas informações fiscais e cadastrais.

- Agrupamento Particional: K-Means

Divide 'n' observações em 'k' clusters pré-determinados. Algoritmo iterativo: 1. Inicializa 'k' centróides aleatórios; 2. Associa cada ponto ao centróide mais próximo (distância euclidiana); 3. Recalcula os centróides como a média dos pontos do cluster; 4. Repete até a convergência. Métodos de escolha do 'k' ótimo: Método do Cotovelo (Elbow Method - ponto de inflexão da soma dos quadrados intra-cluster / WCSS) e Coeficiente de Silhueta (varia de -1 a +1; valores próximos a +1 indicam clusters densos e bem separados).

- Agrupamento Baseado em Densidade: DBSCAN

Agrupa pontos com base na densidade de vizinhança definida por dois parâmetros: Epsilon (raio máximo de vizinhança) e MinPts (número mínimo de pontos para formar um núcleo denso). Classifica pontos em: Pontos Núcleo, Pontos de Borda e Ruído / Outliers. Vantagens: NÃO exige definir o número 'k' de clusters previamente, identifica clusters de formatos arbitrários não esféricos e isola automaticamente outliers fiscais.

- Agrupamento Hierárquico

Gera uma árvore hierárquica de agrupamentos representada em um Dendrograma. Abordagem Aglomerativa (Bottom-Up: cada ponto inicia como um cluster e vai se fundindo) versus Divisiva (Top-Down: inicia com um cluster único e vai se dividindo). Métodos de ligação: Single Linkage (distância mínima), Complete Linkage (distância máxima) e Average Linkage (distância média).

- Mineração de Regras de Associação: Algoritmo Apriori

Descobre relações de coocorrência do tipo 'Se {A}, então {B}' em transações comerciais. Métricas fundamentais: 1. Suporte: $P(A \cap B) = \frac{\text{Transações com } A \text{ e } B}{\text{Total de Transações}}$; 2. Confiança: $P(B|A) = \frac{P(A \cap B)}{P(A)}$; 3. Lift: $\frac{P(A \cap B)}{P(A) \times P(B)}$ (Lift > 1 indica associação positiva relevante; Lift $= 1$ indica independência; Lift < 1 indica associação negativa).

ALERTA DE PROVA - K-MEANS VERSUS DBSCAN

O K-Means é altamente sensível a outliers e assume clusters esféricos de tamanhos similares. O DBSCAN é imune a essa limitação, identificando agrupamentos com formatos orgânicos complexos e descartando ruídos automaticamente.

6. Avaliação de Modelos, Matriz de Confusão e Curva ROC

A avaliação criteriosa de modelos preditivos é indispensável para mensurar sua capacidade de generalização e evitar os fenômenos de Underfitting e Overfitting. A escolha da métrica correta deve refletir o custo operacional do erro no contexto da fiscalização tributária.

- **O Trade-off Viés-Variância (Bias-Variance Tradeoff)**

Underfitting (Alto Viés / Baixa Variância): O modelo é excessivamente simplista para capturar a complexidade dos dados, apresentando alto erro tanto no treino quanto no teste. Overfitting (Baixo Viés / Alta Variância): O modelo decora o conjunto de treino (incluindo ruídos), apresentando excelente desempenho no treino e péssimo desempenho no teste.

- **Técnicas de Validação Cruzada (Cross-Validation)**

K-Fold Cross-Validation: Divide os dados em 'k' partes iguais; treina em 'k-1' partes e testa na parte restante, repetindo 'k' vezes para obter a média do desempenho. Stratified K-Fold: Preserva a proporção original das classes em cada fold (mandatório para bases fiscais desbalanceadas, onde fraudes representam menos de 1% dos dados).

- **Matriz de Confusão para Classificação Binária**

Quatro quadrantes fundamentais: Verdadeiro Positivo (VP - Fraude identificada corretamente), Verdadeiro Negativo (VN - Contribuinte regular classificado corretamente), Falso Positivo (FP / Erro Tipo I - Contribuinte honesto apontado incorretamente como fraudador), Falso Negativo (FN / Erro Tipo II - Fraude real que passou despercebida pelo sistema).

- **Métricas de Desempenho**

Acurácia: $\frac{VP + VN}{Total}$ (inadequada para bases desbalanceadas); Precisão: $\frac{VP}{VP + FP}$ (proporção de alertas de fraude que eram realmente fraudes - mede a assertividade da fiscalização); Revocação / Sensibilidade / Recall: $\frac{VP}{VP + FN}$ (proporção de fraudes reais capturadas pelo modelo - mede a cobertura da malha fina); F1-Score: Média harmônica entre Precisão e Revocação: $2 \times \frac{\text{Precisão} \times \text{Revocação}}{\text{Precisão} + \text{Revocação}}$.

- **Curva ROC e Métrica AUC-ROC**

A Curva ROC plota a Taxa de Verdadeiros Positivos (Sensibilidade) no eixo Y contra a Taxa de Falsos Positivos ($1 - \text{Especificidade}$) no eixo X para múltiplos pontos de corte (thresholds). A métrica AUC (Área sob a Curva ROC) varia de 0,5 (modelo aleatório equivalente a jogar moeda) a 1,0 (classificador perfeito).

A ARMADILHA DA ACURÁCIA EM FRAUDES FISCAIS

Em uma base onde 99% das notas fiscais são idôneas e 1% são fraudulentas, um modelo ingênuo que classifique TODAS as notas como 'idôneas' terá 99% de Acurácia, mas terá 0% de Recall e será completamente inútil para o Fisco!

7. Arquitetura de Big Data e o Ecossistema Apache Hadoop

Big Data refere-se a conjuntos de dados cujo volume, velocidade de geração e variedade de formatos inviabilizam o armazenamento e processamento por sistemas de bancos de dados relacionais tradicionais. A gestão contemporânea de Big Data assenta-se no paradigma de computação distribuída em clusters de hardware comum (Commodity Hardware).

- **Os 5 Vs do Big Data**

Volume (escala de petabytes a exabytes), Velocidade (fluxos de dados gerados e processados em tempo real), Variedade (dados estruturados como tabelas SQL, semiestruturados como XML/JSON e não estruturados como imagens e vídeos), Veracidade (qualidade, autenticidade e confiabilidade da fonte) e Valor (relevância dos insights para as decisões estratégicas do Fisco).

- **HDFS (Hadoop Distributed File System)**

Sistema de arquivos distribuído baseado no padrão Mestre-Escravo (Master-Slave): 1. NameNode (Mestre): Gerencia o namespace do sistema de arquivos e mantém a tabela de metadados em memória RAM; 2. DataNodes (Escravos): Armazenam os blocos físicos de dados no disco local; 3. Replicação de Blocos: Cada bloco de dados (tamanho padrão de 128 MB no Hadoop 2.x/3.x) é replicado por padrão em 3 nós distintos (fator de replicação 3) com tolerância automática a falhas.

- **YARN (Yet Another Resource Negotiator)**

Camada de gerenciamento de recursos e escalonamento de tarefas do Hadoop, composta pelo ResourceManager central e NodeManagers locais em cada nó do cluster.

- **O Paradigma de Programação MapReduce**

Processamento em lote distribuído estruturado em três fases principais: 1. Fase Map: Aplica uma função de transformação sobre os dados de entrada, gerando pares intermediários chave-valor \$(chave, valor)\$; 2. Fase Shuffle and Sort: Agrupa e ordena automaticamente todos os valores associados à mesma chave intermediária; 3. Fase Reduce: Aplica uma função agregadora sobre os valores de cada chave, gerando o resultado consolidado final.

ALERTA DE PROVA - NAMENODE

O NameNode do HDFS armazena apenas METADADOS (estrutura de diretórios, permissões e mapeamento de quais blocos estão em quais DataNodes). O NameNode NUNCA armazena os blocos de dados dos arquivos dos usuários.

8. Processamento Distribuído em Memória com Apache Spark

O Apache Spark é um motor de computação unificado e ultra-rápido para processamento de dados em larga escala. Desenvolvido para superar o gargalo de I/O em disco do MapReduce tradicional do Hadoop, o Spark executa operações mantendo os dados intermediários diretamente na memória RAM (In-Memory Processing), alcançando velocidades até 100 vezes superiores.

- **Arquitetura do Apache Spark**

Driver Program (coordena a execução, cria o SparkContext/SparkSession e gera o Grafo Acíclico Direcionado - DAG), Cluster Manager (aloca recursos via YARN, Mesos, Kubernetes ou Standalone) e Executors (processos executores nos nós de trabalho que processam tarefas e mantêm dados em cache).

- **RDD (Resilient Distributed Datasets)**

Abstração fundamental do Spark: Coleção distribuída de objetos imutável, particionada e tolerante a falhas por meio de Linhagem (Lineage Graph - capacidade de reconstruir qualquer partição perdida reexecutando as transformações originais).

- **Operações em RDD: Transformações versus Ações**

Transformações: Criam um novo RDD a partir de um RDD existente (ex: map, filter, flatMap, groupByKey, reduceByKey, join). Operam sob o conceito de Execução Tardia (Lazy Evaluation) - não são executadas imediatamente, apenas registradas no DAG; Ações: Disparam a execução física do plano de computação do DAG e retornam um valor ao Driver ou gravam dados no armazenamento (ex: count, collect, reduce, first, take, saveAsTextFile).

- **Módulos Integrados do Ecossistema Spark**

Spark SQL (DataFrames e Datasets com otimizador de consultas Catalyst e execução Tungsten), Spark Streaming / Structured Streaming (processamento contínuo de fluxos de eventos em tempo real), Spark MLlib (biblioteca de algoritmos de Machine Learning distribuído) e GraphX (processamento de grafos).

PEGADINHA CLÁSSICA DE SPARK DA FGV

Transformações no Spark NUNCA processam dados no momento da chamada; elas são apenas adicionadas ao plano de execução (Lazy Evaluation). O processamento de fato só ocorre quando uma AÇÃO (como count() ou collect()) é invocada!

9. Processamento de Linguagem Natural e Mineração de Grafos Fiscais

Técnicas avançadas de Inteligência Artificial voltadas para a análise de dados textuais não estruturados (descrições de produtos em NF-e, contratos sociais, defesas de autos de infração) e redes complexas de relacionamentos societários e financeiros.

- **Pipeline de Processamento de Linguagem Natural (PLN / NLP)**

1. Tokenização: Divisão do texto em palavras ou tokens individuais; 2. Remoção de Stopwords: Eliminação de palavras de alta frequência sem conteúdo semântico distintivo (artigos, preposições); 3. Normalização Léxica: Stemming (redução de palavras ao radical bruto por regras heurísticas, ex: Algoritmo de Porter) versus Lematização (redução à forma canônica de dicionário com base na classe gramatical via análise morfológica).

- **Vetorização Textual: TF-IDF versus Embeddings**

TF-IDF (Term Frequency - Inverse Document Frequency): Pondera a frequência do termo no documento pelo inverso de sua frequência no corpus, destacando termos raros e específicos de fraudes; Embeddings Vetoriais (Word2Vec, FastText, BERT): Mapeiam palavras e textos em vetores densos de números reais onde termos semanticamente similares ficam próximos no espaço geométrico multidimensional.

- **Mineração de Grafos na Fiscalização Tributária**

Modelagem de dados em Vértices (empresas, sócios, procuradores, contas bancárias) e Arestas (vínculos societários, transferências financeiras, emissões de notas fiscais). Detecção de comunidades (Algoritmo de Louvain), medidas de Centralidade de Grau, Proximidade e Intermediação (Betweenness Centrality - identifica o operador central de esquemas de lavagem de dinheiro), e algoritmos de detecção de ciclos para coibir operações triangulares de crédito fictício de ICMS.

STEMMING VERSUS LEMATIZAÇÃO

Stemming corta o final da palavra podendo gerar radicais que não existem no dicionário (ex: 'estudante' -> 'estud'). Lematização utiliza o vocabulário e a análise morfológica para retornar o lema real da palavra (ex: 'estudando' -> 'estudar', 'melhores' -> 'bom').

10. As 10 Grandes Armadilhas de Ciência de Dados e Big Data da FGV/CEBRASPE

Quadro analítico com as 10 principais armadilhas de Ciência de Dados, Machine Learning e Big Data cobradas pelas bancas examinadoras em concursos de Auditor Fiscal.

- **Pegadinha 1: Lazy Evaluation no Spark**
Chamar ``rdd.map()`` ou ``rdd.filter()`` não consome CPU nem lê dados imediatamente; a execução real só inicia quando uma ação (``count()``, ``collect()``) é disparada.
- **Pegadinha 2: NameNode armazena Metadados, não Dados**
O NameNode do HDFS armazena exclusivamente a árvore de metadados em memória RAM. Os blocos de dados dos arquivos residem nos DataNodes.
- **Pegadinha 3: Lasso (L1) Zera Coeficientes, Ridge (L2) Não**
Lasso é seleção de variáveis porque zera os coeficientes de atributos irrelevantes. Ridge apenas encolhe os coeficientes.
- **Pegadinha 4: Acurácia em Bases Desbalanceadas**
Acurácia alta em dados desbalanceados é ilusória. Para detecção de fraudes fiscais raras, as métricas mandatórias são Recall, Precisão e F1-Score.
- **Pegadinha 5: K-Means Exige Definição Prévia de 'k'**
O K-Means não descobre o número de clusters sozinho; o usuário é obrigado a fornecer o parâmetro 'k'. O DBSCAN, por outro lado, descobre o número de clusters automaticamente.
- **Pegadinha 6: Invariância de Árvores de Decisão à Escala**
Random Forest e Gradient Boosting NÃO exigem normalização ou padronização de dados numéricos; operam com base na ordenação relativa dos valores.
- **Pegadinha 7: Premissa Ingênua do Naive Bayes**
O Naive Bayes assume independência CONDICIONAL entre todos os atributos dada a classe, o que raramente é verdade na prática, mas ainda assim produz excelentes classificações.
- **Pegadinha 8: Curva ROC e AUC de Classificador Aleatório**
Um modelo que classifica por chute aleatório tem $AUC = 0,50$ (linha diagonal tracejada). Um classificador perfeito tem $AUC = 1,00$.
- **Pegadinha 9: Underfitting é Alto Viés, Overfitting é Alta Variância**
Underfitting decorre de modelo fraco/simples. Overfitting decorre de modelo hipercomplexo que memoriza o ruído do treino.
- **Pegadinha 10: RDDs são Imutáveis**
No Apache Spark, RDDs são coleções 100% imutáveis. Qualquer transformação gera um NOVO RDD, mantendo o grafo de linhagem original intacto para recuperação de falhas.

SÍNTESE FINAL DE MEMORIZAÇÃO

Lembre-se: Spark transforma preguiçosamente (lazy); Lasso zera (L1); em fraudes raras olhe Recall e F1, nunca Acurácia; e no HDFS o NameNode só guarda metadados!

GLOSSÁRIO DE SIGLAS E ABREVIATURAS

Consulte abaixo o significado e a expansão explicativa de todas as siglas contábeis, tributárias e de TI presentes nas apostilas de preparação:

ACID	Atomicidade, Consistência, Isolamento e Durabilidade. Propriedades fundamentais para transações em SGBDs.
BI	Business Intelligence. Inteligência de Negócios para mineração e análise estratégica de dados.
CAP	Consistência, Disponibilidade e Tolerância a Partições. Teorema limitador para sistemas distribuídos.
CEBRASPE	Centro de Seleção e de Promoção de Eventos. Banca examinadora oficial de concursos públicos.
CFC	Conselho Federal de Contabilidade. Órgão responsável pela edição das NBCs no território nacional.
CIAP	Controle de Crédito de ICMS do Ativo Permanente. Controle fiscal de apropriação de créditos de bens imobilizados.
CID	Confidencialidade, Integridade e Disponibilidade. Pilares de sustentação da Segurança da Informação.
COBIT	Control Objectives for Information and Related Technologies. Framework global de Governança de TI.
CPC	Comitê de Pronunciamentos Contábeis. Emissor de normas convergentes com padrões internacionais.
FGV	Fundação Getulio Vargas. Banca examinadora de certames e instituição de pesquisa econômica.
ICMS	Imposto sobre Operações Relativas à Circulação de Mercadorias e Prestações de Serviços de Transporte.
IPVA	Imposto sobre a Propriedade de Veículos Automotores. Tributo de competência estadual.
ITD	Imposto sobre Transmissão Causa Mortis e Doação. Tributo sobre heranças e doações na Bahia.
ITIL	Information Technology Infrastructure Library. Boas práticas de Gerenciamento de Serviços de TI.
KDD	Knowledge Discovery in Databases. Processo sistemático de descoberta de conhecimento em bases de dados.
LDO	Lei de Diretrizes Orçamentárias. Define as metas e prioridades para o orçamento do exercício seguinte.
LOA	Lei Orçamentária Anual. Estima as receitas e fixa as despesas públicas para o exercício financeiro.
NBC TA	Normas Brasileiras de Contabilidade Técnicas de Auditoria Independente. Alinhadas ao padrão internacional.
NBC TI	Normas Brasileiras de Contabilidade Técnicas de Auditoria Interna. Foco nos processos organizacionais.
NoSQL	Not Only SQL. Família de SGBDs não relacionais estruturados para alto desempenho e escalabilidade.
OLAP	Online Analytical Processing. Ferramentas analíticas baseadas em cubos de dados multidimensionais.
PAF-BA	Processo Administrativo Fiscal do Estado da Bahia. Lei nº 3.956/1981 que regula o contencioso.
PPA	Plano Plurianual. Planejamento estratégico governamental de médio prazo (4 anos).
RICMS-BA	Regulamento do ICMS do Estado da Bahia. Decreto regulamentador do principal imposto estadual.
RUP	Rational Unified Process. Processo de desenvolvimento de software disciplinado e preditivo.
SEFAZ-BA	Secretaria da Fazenda do Estado da Bahia. Órgão de arrecadação e controle fiscal baiano.

SGBD	Sistema de Gerenciamento de Banco de Dados. Software de controle e armazenamento seguro de dados.
SQL	Structured Query Language. Linguagem declarativa padrão para consulta em SGBDs relacionais.
TI	Tecnologia da Informação. Recursos de hardware, software e infraestrutura de rede corporativa.
XP	Extreme Programming. Metodologia ágil de engenharia de software focada em excelência técnica.