

Manual: Ciencia de Dados e Big Data

Conceitos e 5 Vs do Big Data, Ecossistema Hadoop e Spark, Bancos NoSQL, Teorema CAP, Processo KDD, Mineração e Algoritmos de Machine Learning

CHANCELA EDITORIAL YLUNA85 LABS

Preparação Conjunta: Auditor Fiscal (TI) & Agente de Tributos Estaduais

Revisão Ortográfica e Glossário Geral de Siglas

Material de livre circulação interna. Revisado em Português Brasileiro (pt-BR).

1. Conceitos de Big Data e os 5 Vs

Big Data refere-se a conjuntos de dados extremamente volumosos e complexos que são difíceis ou impossíveis de serem processados e analisados de forma eficiente utilizando ferramentas tradicionais de banco de dados relacional. Os 5 Vs do Big Data

- **Volume:**
A quantidade massiva de dados gerados a cada segundo. Escala de Terabytes, Petabytes e Exabytes. Ex: registros de logs globais.
- **Velocidade:**
A rapidez com que os novos dados são criados é a necessidade de processamento em tempo real (real-time) ou quase real. Ex: dados de transações financeiras.
- **Variedade:**
Os diferentes tipos e formatos de dados estruturados, semi-estruturados (JSON, XML) e não-estruturados (imagens, audios, posts de redes sociais).
- **Veracidade:**
O grau de confiabilidade, qualidade, precisão e consistência dos dados capturados de fontes diversas.
- **Valor:**
O benefício econômico ou de negócios gerado a partir da análise e transformação desses dados em insights acionáveis.

ESTRUTURAÇÃO DE DADOS

Dados estruturados possuem formato rígido (tabelas SQL com PK e tipos definidos). Dados semi-estruturados possuem tags ou marcadores estruturais flexíveis (JSON, XML). Dados não-estruturados não tem formato predefinido (ex: pdfs digitalizados, vídeos), representando mais de 80% dos dados mundiais.

2. Ecossistema Apache Hadoop: HDFS e MapReduce

O Apache Hadoop é um framework de software open-source de código aberto para armazenamento e processamento distribuído de grandes volumes de dados em clusters de computadores comuns. HDFS (Hadoop Distributed File System) O sistema de arquivos distribuído do Hadoop, projetado para ser tolerante a falhas. Baseia-se na arquitetura Mestre/Escravo:

- **NameNode (Mestre):**
Gerencia o espaço de nomes do sistema de arquivos (metadados), controla o acesso dos clientes e mapeia os blocos de dados para os DataNodes. Existe apenas um NameNode ativo no cluster básico (ponto único de falha).
 - **DataNode (Escravo):**
Responsável por armazenar e recuperar os blocos de dados reais em disco físico conforme instruções do NameNode, reportando-se periodicamente a ele.
 - **Replicação de Blocos:**
O HDFS divide os arquivos em grandes blocos (ex: 128 MB) e os replica (padrão 3 cópias) em diferentes servidores para garantir tolerância a falhas. O Modelo MapReduce Modelo de programação distribuída para processar grandes volumes de dados em paralelo:
 - **Map (Mapeamento):**
Fase de filtragem e distribuição. Recebe um conjunto de dados e o transforma em pares de chave-valor intermediários.
 - **Shuffle & Sort (Embaralhamento):**
Fase intermediária automática do Hadoop que agrupa os pares com chaves idênticas.
 - **Reduce (Redução):**
Fase de agregação. Recebe os grupos e combina os valores intermediários para gerar o resultado final consolidado.
- YARN - AGENDADOR DO HADOOP O YARN (Yet Another Resource Negotiator) é o gerenciador de recursos introduzido no Hadoop 2.0. Ele separa o gerenciamento de recursos do processamento MapReduce, permitindo que outros frameworks de execução (como o Spark) rodem sobre o mesmo cluster HDFS.

3. Processamento em Memória: Apache Spark

O Apache Spark é um framework de computação distribuída projetado para processamento ultrarrápido de dados, superando o Hadoop MapReduce em até 100 vezes rodando em memória. Conceito de RDD (Resilient Distributed Dataset) O RDD é a abstração de dados fundamental do Spark, representando uma coleção de objetos tolerante a falhas e distribuída que pode ser processada em paralelo.

- **Imutabilidade:**
Um RDD não pode ser modificado uma vez criado. Para alterá-lo, aplica-se uma transformação que gera um novo RDD.
- **Avaliação Preguiçosa (Lazy Evaluation):**
As transformações em RDDs (ex: map, filter) não são executadas imediatamente; o Spark apenas registra o plano de execução. A execução real ocorre apenas quando uma ação (ex: count, collect, save) é invocada.
- **Tolerância a Falhas (Linhagem):**
Se uma partição de RDD for perdida, ela pode ser reconstruída automaticamente aplicando a linhagem (grafo de transformações) sobre a fonte de dados original. Módulos Integrados do Spark
- **Spark SQL:**
Permite executar consultas SQL estruturadas e trabalhar com DataFrames e DataSets.
- **Spark Streaming:**
Permite o processamento de fluxos de dados em tempo real (streaming).
- **Spark MLlib:**
Biblioteca integrada de algoritmos de aprendizado de máquina distribuído.

SPARK VS. MAPREDUCE

Enquanto o MapReduce escreve resultados intermediários em disco (gerando alta latência por I/O), o Spark mantém os dados intermediários na memória RAM (in-memory) ao longo de todo o fluxo de execução, tornando-o ideal para algoritmos iterativos (Machine Learning).

4. Bancos de Dados NoSQL é o Teorema CAP

Bancos NoSQL (Not Only SQL) são sistemas de banco de dados não-relacionais projetados para alta escalabilidade horizontal, performance e flexibilidade de esquema. O Teorema CAP (Teorema de Brewer) Dita que um sistema distribuído de dados pode garantir, no máximo, DUAS das seguintes três propriedades simultaneamente:

- **Consistência (Consistency):**
Todos os nós do cluster leem o mesmo dado ao mesmo tempo (o dado atualizado e refletido imediatamente em todos os nós).
- **Disponibilidade (Availability):**
Toda requisição de leitura/escrita recebe uma resposta de sucesso ou falha (sem erro ou timeout), mesmo que alguns nós estejam inativos.
- **Tolerância a Partição (Partition Tolerance):**
O sistema continua operando mesmo que haja quebra de conexão de rede (partição) entre os nós do cluster. A tolerância a partição é obrigatória em sistemas distribuídos na nuvem. Categorias de NoSQL
- **Chave-Valor (Key-Value):**
Armazena pares simples de chaves associadas a valores brutos. Alta velocidade. Ex: Redis, DynamoDB.
- **Documento (Document):**
Armazena dados como documentos estruturados (JSON ou BSON). Ex: MongoDB, CouchDB.
- **Família de Colunas (Wide-column):**
Armazena dados em linhas contendo colunas flexíveis dinâmicas. Ex: Cassandra, HBase.
- **Grafos (Graph):**
Armazena dados estruturados como Nós (entidades) e Arestas (relacionamentos). Ex: Neo4j.

ESCOLHA CAP NA NUVEM

Como falhas de rede na nuvem são inevitáveis, a Tolerância a Partição (P) é obrigatória. Resta aos bancos NoSQL escolher entre: ser AP (Disponibilidade e Tolerância, sacrificando a consistência imediata por consistência eventual) ou CP (Consistência e Tolerância, bloqueando operações se houver falha de sincronia).

5. O Processo KDD e Mineracao de Dados

Mineração de Dados (Data Mining) é a fase automatica ou semi-automatica de extracao de padroes ocultos inovadores de grandes bases de dados, inserida no processo KDD (Knowledge Discovery in Databases). As Etapas do Processo KDD

- **1. Selecao:**
Definicao da base de dados e variaveis alvo relevantes para o objetivo.
- **2. Pre-processamento (Limpeza):**
Tratamento de dados faltantes (nulos), correcao de ruidos e remocao de registros inconsistentes.
- **3. Transformacao:**
Adequação dos formatos (ex: normalizar escala numerica, converter texto para numérico).
- **4. Mineracao de Dados (Data Mining):**
Aplicação de algoritmos específicos para identificar associacoes, agrupamentos ou modelos preditivos.
- **5. Avaliacao e Interpretação:**
Análise visual e metrica dos padroes descobertos para validar se geram conhecimento útil. Metodos de Mineracao e Regras de Associacao O Algoritmo Apriori identifica padroes de compras conjuntas (ex: 'Quem compra cerveja tambem compra fraldas'). Suas metricas principais sao:
 - **Support (Support):**
Proporcao de transações totais que contem os itens A e B juntos.
 - **Confianca (Confidence):**
Probabilidade de comprar B dado que A foi comprado. $P(B|A)$.
 - **Lift (Alavancagem):**
Indica o grau de dependencia entre A e B. Se $Lift > 1$, ha forte associacao positiva. Se $Lift \leq 1$, os itens sao independentes.

LIMPEZA DE DADOS

A fase de pre-processamento e considerada a mais demorada do KDD (representando mais de 60% do esforco), pois dados reais sao repletos de ruidos, erros de preenchimento ou dados faltantes que invalidam a mineracao.

6. Aprendizado de Maquina Supervisionado

O Aprendizado de Maquina (Machine Learning) capacita computadores a aprender a partir de dados historicos sem programacao explicita. Divide-se em Supervisionado e Não Supervisionado. Aprendizado Supervisionado Os dados de treino incluem a resposta correta (rotulos/labels). O objetivo e aprender a mapear entradas para a saida rotulada. Divide-se em:

- **Classificacao (Saidas Categoricas):**

Prever uma classe ou categoria. Ex: prever se uma transação e fraudulenta (Sim ou Não), classificar se um e-mail e spam. Algoritmos principais: Regressao Logistica, Arvore de Decisao, Random Forest, SVM (Support Vector Machine), Naive Bayes, e KNN (K-Nearest Neighbors).

- **Regressao (Saidas Continuas/Numericas):**

Prever um valor numerico continuo. Ex: prever a arrecadação do ICMS no proximo mes, prever o preco de um imovel. Algoritmos principais: Regressao Linear Simples e Multipla, Arvore de Regressao. Destaque de Algoritmos

- **Naive Bayes (Probabilistico):**

Baseado no Teorema de Bayes, assume independência condicional ingenua entre todos os atributos. Muito usado para classificacao de textos e análise de sentimento.

- **Random Forest (Floresta Aleatoria):**

Algoritmo de ensemble que cria multiplas arvores de decisao e combina suas predicoes (votacao da maioria) para reduzir o over-fitting e aumentar a precisao. OVER-FITTING (SOBREAJUSTE) Ocorre quando o modelo de aprendizado de maquina se decora excessivamente com os dados de treino (aprendendo ate os ruidos), perdendo a capacidade de generalizar para novos dados de teste não vistos. O modelo tem alta acuracia no treino e baixa acuracia no teste.

7. Aprendizado de Máquina Não Supervisionado

No Aprendizado Não Supervisionado, os dados não possuem rótulos ou respostas corretas fornecidas. O algoritmo deve encontrar estruturas, agrupamentos ou padrões inerentes ocultos. Agrupamento (Clustering) Objetivo: agrupar itens de forma que elementos no mesmo grupo sejam muito semelhantes entre si e muito diferentes de elementos em outros grupos.

- **Algoritmo K-Means (Baseado em Centroides):**

Divide a população em K grupos predefinidos pelo usuário. Funciona de forma iterativa: 1) Define aleatoriamente K centroides; 2) Associa cada ponto ao centroide mais próximo; 3) Recalcula a posição dos centroides com base na média dos pontos do grupo; 4) Repete até a convergência.

- **Algoritmo DBSCAN (Baseado em Densidade):**

Agrupar pontos próximos em regiões de alta densidade e isolar pontos em regiões de baixa densidade como ruídos (outliers). Não exige definir o número de grupos K previamente e detecta grupos de formatos irregulares. Redução de Dimensionalidade Objetivo: reduzir o número de atributos (colunas) da base de dados, preservando o máximo de informação e variância possíveis para simplificar o modelo.

- **PCA (Principal Component Analysis):**

Transforma variáveis correlacionadas em um conjunto menor de variáveis não correlacionadas chamadas de Componentes Principais. SENSIBILIDADE A OUTLIERS NO K-MEANS O K-Means é altamente sensível a outliers (valores extremos), pois o centroide é calculado pela média aritmética dos pontos. Um outlier puxará o centroide em sua direção, distorcendo os grupos formados.

8. Avaliacao de Modelos e Matriz de Confusao

Para validar a qualidade de modelos de aprendizado de maquina de classificacao, os dados sao divididos em treino e teste, e aplica-se a Matriz de Confusao. A Matriz de Confusao Quadro de 2x2 que cruza os valores reais com as previsões do modelo:

- **Verdadeiro Positivo (VP):**
O dado era positivo é o modelo previu positivo (acerto).
- **Falso Positivo (FP - Erro Tipo I):**
O dado era negativo é o modelo previu positivo (erro).
- **Falso Negativo (FN - Erro Tipo II):**
O dado era positivo é o modelo previu negativo (erro).
- **Verdadeiro Negativo (VN):**
O dado era negativo é o modelo previu negativo (acerto). Metricas de Desempenho
- **Acuracia (Accuracy):**
Proporcao total de acertos do modelo. Formula: $(VP + VN) / Total$. Pode ser enganosa em bases de dados muito desbalanceadas.
- **Precisao (Precision):**
Proporcao de acertos dentre as previsões positivas. Formula: $VP / (VP + FP)$. Importante quando o custo do Falso Positivo e alto.
- **Recall (Sensibilidade / Revogacao):**
Proporcao de acertos dentre a classe real positiva. Formula: $VP / (VP + FN)$. Importante quando o custo do Falso Negativo e alto (ex: detectar fraude de ICMS ou diagnostico de doenca).
- **F1-Score:**
Media harmonica entre Precisao e Recall, ideal para bases desbalanceadas.

CURVA ROC E AUC

A Curva ROC plota a taxa de verdadeiros positivos contra a taxa de falsos positivos. A AUC (Area Under the Curve) mede o desempenho geral do modelo de classificacao: varia de 0.5 (modelo aleatorio) a 1.0 (modelo perfeito). Em concursos, um AUC de 0.9 e considerado excelente.

9. As 10 Grandes Pegadinhas de Ciencia de Dados

As bancas FGV e Cebraspe mapeiam armadilhas recorrentes sobre Big Data e Machine Learning:

- **1. Ponto único de falha no HDFS:**
No Hadoop 1.x classico, o NameNode é o ponto único de falha (Single Point of Failure). O DataNode apenas armazena dados, sem controle administrativo.
- **2. Fase Shuffle & Sort e automatica:**
No MapReduce, a fase de embaralhamento (Shuffle) ocorre de forma automatica pelo framework para agrupar chaves. Não é programada pelo usuário.
- **3. Imutabilidade do RDD no Spark:**
Os RDDs são imutáveis. Aplicar uma transformação não altera o RDD original; cria um novo. A linhagem do Spark registra isso.
- **4. Ações vs. Transformações no Spark:**
Transformações (ex: filter, map) não são executadas até que uma ação (ex: count, collect) seja invocada (Lazy Evaluation).
- **5. Teorema CAP é a impossibilidade das três propriedades:**
Nenhum sistema distribuído de dados pode garantir Consistência, Disponibilidade e Tolerância (C, A e P) ao mesmo tempo em caso de partição de rede.
- **6. Consistência Eventual e AP:**
Bancos NoSQL AP sacrificam a consistência imediata (dados atualizados em tempo real em todos os nós) em prol da alta disponibilidade, garantindo consistência eventual.
- **7. Pre-processamento é a fase mais lenta do KDD:**
A limpeza e preparação de dados consomem mais de 60% do tempo de projetos de ciência de dados reais, e não a execução do algoritmo de IA.
- **8. Naive Bayes é a premissa de independência:**
O classificador Naive Bayes assume que todos os atributos são 100% independentes entre si (ex: tamanho e cor do fruto), premissa não real em dados naturais.
- **9. Acurácia enganosa em dados desbalanceados:**
Se uma base tem 99% de transações normais e 1% de fraudes, um modelo que apenas prevê 'Normal' terá 99% de acurácia, mas será inútil para detectar fraudes.
- **10. K-Means exige K predefinido pelo usuário:**
O K-Means exige que o número de grupos K seja definido antes de rodar o algoritmo. Algoritmos de densidade (DBSCAN) não exigem essa definição.

FICHA DE REVISÃO GERAL

Foque os estudos finais nas diferenças de Precisão vs Recall na Matriz de Confusão, propriedades ACID vs CAP, lazy evaluation de RDDs do Spark e etapas do KDD.

GLOSSÁRIO DE SIGLAS E ABREVIATURAS

Consulte abaixo o significado e a expansão explicativa de todas as siglas contábeis, tributárias e de TI presentes nas apostilas de preparação:

ACID	Atomicidade, Consistência, Isolamento e Durabilidade. Propriedades fundamentais para transações em SGBDs.
BI	Business Intelligence. Inteligência de Negócios para mineração e análise estratégica de dados.
CAP	Consistência, Disponibilidade e Tolerância a Partições. Teorema limitador para sistemas distribuídos.
CEBRASPE	Centro de Seleção e de Promoção de Eventos. Banca examinadora oficial de concursos públicos.
CFC	Conselho Federal de Contabilidade. Órgão responsável pela edição das NBCs no território nacional.
CIAP	Controle de Crédito de ICMS do Ativo Permanente. Controle fiscal de apropriação de créditos de bens imobilizados.
CID	Confidencialidade, Integridade e Disponibilidade. Pilares de sustentação da Segurança da Informação.
COBIT	Control Objectives for Information and Related Technologies. Framework global de Governança de TI.
CPC	Comitê de Pronunciamentos Contábeis. Emissor de normas convergentes com padrões internacionais.
FGV	Fundação Getulio Vargas. Banca examinadora de certames e instituição de pesquisa econômica.
ICMS	Imposto sobre Operações Relativas à Circulação de Mercadorias e Prestações de Serviços de Transporte.
IPVA	Imposto sobre a Propriedade de Veículos Automotores. Tributo de competência estadual.
ITD	Imposto sobre Transmissão Causa Mortis e Doação. Tributo sobre heranças e doações na Bahia.
ITIL	Information Technology Infrastructure Library. Boas práticas de Gerenciamento de Serviços de TI.
KDD	Knowledge Discovery in Databases. Processo sistemático de descoberta de conhecimento em bases de dados.
LDO	Lei de Diretrizes Orçamentárias. Define as metas e prioridades para o orçamento do exercício seguinte.
LOA	Lei Orçamentária Anual. Estima as receitas e fixa as despesas públicas para o exercício financeiro.
NBC TA	Normas Brasileiras de Contabilidade Técnicas de Auditoria Independente. Alinhadas ao padrão internacional.
NBC TI	Normas Brasileiras de Contabilidade Técnicas de Auditoria Interna. Foco nos processos organizacionais.
NoSQL	Not Only SQL. Família de SGBDs não relacionais estruturados para alto desempenho e escalabilidade.
OLAP	Online Analytical Processing. Ferramentas analíticas baseadas em cubos de dados multidimensionais.
PAF-BA	Processo Administrativo Fiscal do Estado da Bahia. Lei nº 3.956/1981 que regula o contencioso.
PPA	Plano Plurianual. Planejamento estratégico governamental de médio prazo (4 anos).
RICMS-BA	Regulamento do ICMS do Estado da Bahia. Decreto regulamentador do principal imposto estadual.
RUP	Rational Unified Process. Processo de desenvolvimento de software disciplinado e preditivo.
SEFAZ-BA	Secretaria da Fazenda do Estado da Bahia. Órgão de arrecadação e controle fiscal baiano.

SGBD	Sistema de Gerenciamento de Banco de Dados. Software de controle e armazenamento seguro de dados.
SQL	Structured Query Language. Linguagem declarativa padrão para consulta em SGBDs relacionais.
TI	Tecnologia da Informação. Recursos de hardware, software e infraestrutura de rede corporativa.
XP	Extreme Programming. Metodologia ágil de engenharia de software focada em excelência técnica.