

Manual de Estudos: Ciência de Dados e Big Data

Arquiteturas Distribuídas, Machine Learning, Mineração de Dados e Detecção de Fraudes

PREPARAÇÃO ESTRATÉGICA SEFAZ-BA 2026

Cargos: Auditor Fiscal (TI) & Agente de Tributos Estaduais (Geral)

Linguagem Clara em Português Brasileiro e Glossário Didático de Siglas

Edição revisada: sem jargões obscuros, com explicação de todas as siglas técnicas.

0. Glossário Introdutório de Siglas e Termos da Matéria

Apresentamos o significado didático e direto das principais siglas cobradas nesta disciplina:

- **HDFS:**
Hadoop Distributed File System (Sistema de arquivos distribuído para armazenamento de grandes volumes de dados).
- **ML:**
Machine Learning / Aprendizado de Máquina (Algoritmos que aprendem padrões a partir de dados históricos).
- **NLP:**
Natural Language Processing / Processamento de Linguagem Natural (Análise automatizada de textos e documentos).

1. Os V's do Big Data aplicados à Fiscalização

O ecossistema de Big Data na fiscalização tributária lida com os 5 V's tradicionais: Volume, Velocidade, Variedade, Veracidade e Valor.

- **Detecção de Anomalias:**

Modelos de Machine Learning identificam desvios de padrões em notas fiscais eletrônicas para combater sonegação.

- **Processamento em Tempo Real:**

Ferramentas como Apache Spark processam milhões de eventos fiscais por segundo.

APRENDIZADO SUPERVISIONADO VS NÃO SUPERVISIONADO

No aprendizado supervisionado treinamos modelos com dados rotulados (fraude/não fraude). No não supervisionado o algoritmo agrupa dados por similaridade nativa.