

Manual: Ciencia de Dados e Big Data

Conceitos e 5 Vs do Big Data, Ecossistema Hadoop e Spark, Bancos NoSQL, Teorema CAP, Processo KDD, Mineracao e Algoritmos de Machine Learning

PREPARAÇÃO ESTRATÉGICA SEFAZ-BA 2026

Cargos: Auditor Fiscal (TI) & Agente de Tributos Estaduais (Geral)
Linguagem Clara em Portugues Brasileiro e Glossario Didatico de Siglas

Edicao revisada: sem jargoes obscuros, com explicacao de todas as siglas tecnicas.

1. Conceitos de Big Data e os 5 Vs

Big Data refere-se a conjuntos de dados extremamente volumosos e complexos que são difíceis ou impossíveis de serem processados e analisados de forma eficiente utilizando ferramentas tradicionais de banco de dados relacional. Os 5 Vs do Big Data

- **Volume:**
A quantidade massiva de dados gerados a cada segundo. Escala de Terabytes, Petabytes e Exabytes. Ex: registros de logs globais.
- **Velocidade:**
A rapidez com que os novos dados são criados e a necessidade de processamento em tempo real (real-time) ou quase real. Ex: dados de transações financeiras.
- **Variedade:**
Os diferentes tipos e formatos de dados estruturados, semi-estruturados (JSON, XML) e não-estruturados (imagens, audios, posts de redes sociais).
- **Veracidade:**
O grau de confiabilidade, qualidade, precisão e consistência dos dados capturados de fontes diversas.
- **Valor:**
O benefício econômico ou de negócios gerado a partir da análise e transformação desses dados em insights acionáveis.

ESTRUTURAÇÃO DE DADOS

Dados estruturados possuem formato rígido (tabelas SQL com PK e tipos definidos). Dados semi-estruturados possuem tags ou marcadores estruturais flexíveis (JSON, XML). Dados não-estruturados não tem formato predefinido (ex: pdfs digitalizados, vídeos), representando mais de 80% dos dados mundiais.

2. Ecossistema Apache Hadoop: HDFS e MapReduce

O Apache Hadoop é um framework de software open-source de código aberto para armazenamento e processamento distribuído de grandes volumes de dados em clusters de computadores comuns. HDFS (Hadoop Distributed File System) O sistema de arquivos distribuído do Hadoop, projetado para ser tolerante a falhas. Baseia-se na arquitetura Mestre/Escravo:

- **NameNode (Mestre):**
Gerencia o espaço de nomes do sistema de arquivos (metadados), controla o acesso dos clientes e mapeia os blocos de dados para os DataNodes. Existe apenas um NameNode ativo no cluster básico (ponto único de falha).
 - **DataNode (Escravo):**
Responsável por armazenar e recuperar os blocos de dados reais em disco físico conforme instruções do NameNode, reportando-se periodicamente a ele.
 - **Replicação de Blocos:**
O HDFS divide os arquivos em grandes blocos (ex: 128 MB) e os replica (padrão 3 cópias) em diferentes servidores para garantir tolerância a falhas. O Modelo MapReduce Modelo de programação distribuída para processar grandes volumes de dados em paralelo:
 - **Map (Mapeamento):**
Fase de filtragem e distribuição. Recebe um conjunto de dados e o transforma em pares de chave-valor intermediários.
 - **Shuffle & Sort (Embaralhamento):**
Fase intermediária automática do Hadoop que agrupa os pares com chaves idênticas.
 - **Reduce (Redução):**
Fase de agregação. Recebe os grupos e combina os valores intermediários para gerar o resultado final consolidado.
- YARN - AGENDADOR DO HADOOP O YARN (Yet Another Resource Negotiator) é o gerenciador de recursos introduzido no Hadoop 2.0. Ele separa o gerenciamento de recursos do processamento MapReduce, permitindo que outros frameworks de execução (como o Spark) rodem sobre o mesmo cluster HDFS.

3. Processamento em Memória: Apache Spark

O Apache Spark é um framework de computação distribuída projetado para processamento ultrarrápido de dados, superando o Hadoop MapReduce em até 100 vezes rodando em memória. Conceito de RDD (Resilient Distributed Dataset) O RDD é a abstração de dados fundamental do Spark, representando uma coleção de objetos tolerante a falhas e distribuída que pode ser processada em paralelo.

- **Imutabilidade:**
Um RDD não pode ser modificado uma vez criado. Para alterá-lo, aplica-se uma transformação que gera um novo RDD.
- **Avaliação Preguiçosa (Lazy Evaluation):**
As transformações em RDDs (ex: map, filter) não são executadas imediatamente; o Spark apenas registra o plano de execução. A execução real ocorre apenas quando uma ação (ex: count, collect, save) é invocada.
- **Tolerância a Falhas (Linhagem):**
Se uma partição de RDD for perdida, ela pode ser reconstruída automaticamente aplicando a linhagem (grafo de transformações) sobre a fonte de dados original. Módulos Integrados do Spark
- **Spark SQL:**
Permite executar consultas SQL estruturadas e trabalhar com DataFrames e DataSets.
- **Spark Streaming:**
Permite o processamento de fluxos de dados em tempo real (streaming).
- **Spark MLlib:**
Biblioteca integrada de algoritmos de aprendizado de máquina distribuído.

SPARK VS. MAPREDUCE

Enquanto o MapReduce escreve resultados intermediários em disco (gerando alta latência por I/O), o Spark mantém os dados intermediários na memória RAM (in-memory) ao longo de todo o fluxo de execução, tornando-o ideal para algoritmos iterativos (Machine Learning).

4. Bancos de Dados NoSQL e o Teorema CAP

Bancos NoSQL (Not Only SQL) são sistemas de banco de dados não-relacionais projetados para alta escalabilidade horizontal, performance e flexibilidade de esquema. O Teorema CAP (Teorema de Brewer) Dita que um sistema distribuído de dados pode garantir, no máximo, DUAS das seguintes três propriedades simultaneamente:

- **Consistencia (Consistency):**
Todos os nós do cluster leem o mesmo dado ao mesmo tempo (o dado atualizado e refletido imediatamente em todos os nós).
- **Disponibilidade (Availability):**
Toda requisição de leitura/escrita recebe uma resposta de sucesso ou falha (sem erro ou timeout), mesmo que alguns nós estejam inativos.
- **Tolerancia a Particao (Partition Tolerance):**
O sistema continua operando mesmo que haja quebra de conexão de rede (partição) entre os nós do cluster. A tolerância a partição é obrigatória em sistemas distribuídos na nuvem. Categorias de NoSQL
- **Chave-Valor (Key-Value):**
Armazena pares simples de chaves associadas a valores brutos. Alta velocidade. Ex: Redis, DynamoDB.
- **Documento (Document):**
Armazena dados como documentos estruturados (JSON ou BSON). Ex: MongoDB, CouchDB.
- **Familia de Colunas (Wide-column):**
Armazena dados em linhas contendo colunas flexíveis dinâmicas. Ex: Cassandra, HBase.
- **Grafos (Graph):**
Armazena dados estruturados como Nós (entidades) e Arestas (relacionamentos). Ex: Neo4j.

ESCOLHA CAP NA NUVEM

Como falhas de rede na nuvem são inevitáveis, a Tolerancia a Particao (P) é obrigatória. Resta aos bancos NoSQL escolher entre: ser AP (Disponibilidade e Tolerancia, sacrificando a consistencia imediata por consistencia eventual) ou CP (Consistencia e Tolerancia, bloqueando operacoes se houver falha de sincronia).

5. O Processo KDD e Mineracao de Dados

Mineracao de Dados (Data Mining) e a fase automatica ou semi-automatica de extracao de padroes ocultos inovadores de grandes bases de dados, inserida no processo KDD (Knowledge Discovery in Databases). As Etapas do Processo KDD

- **1. Selecao:**
Definicao da base de dados e variaveis alvo relevantes para o objetivo.
- **2. Pre-processamento (Limpeza):**
Tratamento de dados faltantes (nulos), correcao de ruidos e remocao de registros inconsistentes.
- **3. Transformacao:**
Adequacao dos formatos (ex: normalizar escala numerica, converter texto para numerico).
- **4. Mineracao de Dados (Data Mining):**
Aplicacao de algoritmos especificos para identificar associacoes, agrupamentos ou modelos preditivos.
- **5. Avaliacao e Interpretacao:**
Analise visual e metrica dos padroes descobertos para validar se geram conhecimento util. Metodos de Mineracao e Regras de Associacao O Algoritmo Apriori identifica padroes de compras conjuntas (ex: 'Quem compra cerveja tambem compra fraldas'). Suas metricas principais sao:
 - **Support (Support):**
Proporcao de transacoes totais que contem os itens A e B juntos.
 - **Confianca (Confidence):**
Probabilidade de comprar B dado que A foi comprado. $P(B|A)$.
 - **Lift (Alavancagem):**
Indica o grau de dependencia entre A e B. Se $Lift > 1$, ha forte associacao positiva. Se $Lift \leq 1$, os itens sao independentes.

LIMPEZA DE DADOS

A fase de pre-processamento e considerada a mais demorada do KDD (representando mais de 60% do esforco), pois dados reais sao repletos de ruidos, erros de preenchimento ou dados faltantes que invalidam a mineracao.

6. Aprendizado de Maquina Supervisionado

O Aprendizado de Maquina (Machine Learning) capacita computadores a aprender a partir de dados historicos sem programacao explicita. Divide-se em Supervisionado e Nao Supervisionado. Aprendizado Supervisionado Os dados de treino incluem a resposta correta (rotulos/labels). O objetivo e aprender a mapear entradas para a saida rotulada. Divide-se em:

- **Classificacao (Saidas Categorias):**

Prever uma classe ou categoria. Ex: prever se uma transacao e fraudulenta (Sim ou Nao), classificar se um e-mail e spam. Algoritmos principais: Regressao Logistica, Arvore de Decisao, Random Forest, SVM (Support Vector Machine), Naive Bayes, e KNN (K-Nearest Neighbors).

- **Regressao (Saidas Continuas/Numericas):**

Prever um valor numerico continuo. Ex: prever a arrecadacao do ICMS no proximo mes, prever o preco de um imovel. Algoritmos principais: Regressao Linear Simples e Multipla, Arvore de Regressao. Destaque de Algoritmos

- **Naive Bayes (Probabilistico):**

Baseado no Teorema de Bayes, assume independencia condicional ingenua entre todos os atributos. Muito usado para classificacao de textos e analise de sentimento.

- **Random Forest (Floresta Aleatoria):**

Algoritmo de ensemble que cria multiplas arvores de decisao e combina suas predicoes (votacao da maioria) para reduzir o over-fitting e aumentar a precisao. OVER-FITTING (SOBREAJUSTE) Ocorre quando o modelo de aprendizado de maquina se decora excessivamente com os dados de treino (aprendendo ate os ruidos), perdendo a capacidade de generalizar para novos dados de teste nao vistos. O modelo tem alta acuracia no treino e baixa acuracia no teste.

7. Aprendizado de Maquina Nao Supervisionado

No Aprendizado Nao Supervisionado, os dados nao possuem rotulos ou respostas corretas fornecidas. O algoritmo deve encontrar estruturas, agrupamentos ou padroes inerentes ocultos. Agrupamento (Clustering) Objetivo: agrupar itens de forma que elementos no mesmo grupo sejam muito semelhantes entre si e muito diferentes de elementos em outros grupos.

- **Algoritmo K-Means (Baseado em Centroides):**

Divide a populacao em K grupos predefinidos pelo usuario. Funciona de forma iterativa: 1) Define aleatoriamente K centroides; 2) Associa cada ponto ao centroide mais proximo; 3) Recalcula a posicao dos centroides com base na media dos pontos do grupo; 4) Repete ate a convergencia.

- **Algoritmo DBSCAN (Baseado em Densidade):**

Agrupar pontos proximos em regioes de alta densidade e isola pontos em regioes de baixa densidade como ruidos (outliers). Nao exige definir o numero de grupos K previamente e detecta grupos de formatos irregulares. Reducao de Dimensionalidade Objetivo: reduzir o numero de atributos (colunas) da base de dados, preservando o maximo de informacao e variancia possiveis para simplificar o modelo.

- **PCA (Principal Component Analysis):**

Transforma variaveis correlacionadas em um conjunto menor de variaveis nao correlacionadas chamadas de Componentes Principais. SENSIBILIDADE A OUTLIERS NO K-MEANS O K-Means e altamente sensivel a outliers (valores extremos), pois o centroide e calculado pela media aritmetica dos pontos. Um outlier puxara o centroide em sua direcao, distorcendo os grupos formados.

8. Avaliacao de Modelos e Matriz de Confusao

Para validar a qualidade de modelos de aprendizado de maquina de classificacao, os dados sao divididos em treino e teste, e aplica-se a Matriz de Confusao. A Matriz de Confusao Quadro de 2x2 que cruza os valores reais com as previsoes do modelo:

- **Verdadeiro Positivo (VP):**
O dado era positivo e o modelo previu positivo (acerto).
- **Falso Positivo (FP - Erro Tipo I):**
O dado era negativo e o modelo previu positivo (erro).
- **Falso Negativo (FN - Erro Tipo II):**
O dado era positivo e o modelo previu negativo (erro).
- **Verdadeiro Negativo (VN):**
O dado era negativo e o modelo previu negativo (acerto). Metricas de Desempenho
- **Acuracia (Accuracy):**
Proporcao total de acertos do modelo. Formula: $(VP + VN) / Total$. Pode ser enganosa em bases de dados muito desbalanceadas.
- **Precisao (Precision):**
Proporcao de acertos dentre as previsoes positivas. Formula: $VP / (VP + FP)$. Importante quando o custo do Falso Positivo e alto.
- **Recall (Sensibilidade / Revogacao):**
Proporcao de acertos dentre a classe real positiva. Formula: $VP / (VP + FN)$. Importante quando o custo do Falso Negativo e alto (ex: detectar fraude de ICMS ou diagnostico de doenca).
- **F1-Score:**
Media harmonica entre Precisao e Recall, ideal para bases desbalanceadas.

CURVA ROC E AUC

A Curva ROC plota a taxa de verdadeiros positivos contra a taxa de falsos positivos. A AUC (Area Under the Curve) mede o desempenho geral do modelo de classificacao: varia de 0.5 (modelo aleatorio) a 1.0 (modelo perfeito). Em concursos, um AUC de 0.9 e considerado excelente.

9. As 10 Grandes Pegadinhas de Ciencia de Dados

As bancas FGV e Cebraspe mapeiam armadilhas recorrentes sobre Big Data e Machine Learning:

- **1. Ponto unico de falha no HDFS:**
No Hadoop 1.x classico, o NameNode e o ponto unico de falha (Single Point of Failure). O DataNode apenas armazena dados, sem controle administrativo.
- **2. Fase Shuffle & Sort e automatica:**
No MapReduce, a fase de embaralhamento (Shuffle) ocorre de forma automatica pelo framework para agrupar chaves. Nao e programada pelo usuario.
- **3. Imutabilidade do RDD no Spark:**
Os RDDs sao imutaveis. Aplicar uma transformacao nao altera o RDD original; cria um novo. A linhagem do Spark registra isso.
- **4. Acoes vs. Transformacoes no Spark:**
Transformacoes (ex: filter, map) nao sao executadas ate que uma acao (ex: count, collect) seja invocada (Lazy Evaluation).
- **5. Teorema CAP e a impossibilidade das tres propriedades:**
Nenhum sistema distribuido de dados pode garantir Consistencia, Disponibilidade e Tolerancia (C, A e P) ao mesmo tempo em caso de particao de rede.
- **6. Consistencia Eventual e AP:**
Bancos NoSQL AP sacrificam a consistencia imediata (dados atualizados em tempo real em todos os nos) em prol da alta disponibilidade, garantindo consistencia eventual.
- **7. Pre-processamento e a fase mais lenta do KDD:**
A limpeza e preparacao de dados consomem mais de 60% do tempo de projetos de ciencia de dados reais, e nao a execucao do algoritmo de IA.
- **8. Naive Bayes e a premissa de independencia:**
O classificador Naive Bayes assume que todos os atributos sao 100% independentes entre si (ex: tamanho e cor do fruto), premissa nao real em dados naturais.
- **9. Acuracia enganosa em dados desbalanceados:**
Se uma base tem 99% de transacoes normais e 1% de fraudes, um modelo que apenas preve 'Normal' tera 99% de acuracia, mas sera inutil para detectar fraudes.
- **10. K-Means exige K predefinido pelo usuario:**
O K-Means exige que o numero de grupos K seja definido antes de rodar o algoritmo. Algoritmos de densidade (DBSCAN) nao exigem essa definicao.

FICHA DE REVISAO GERAL

Foque os estudos finais nas diferencas de Precisao vs Recall na Matriz de Confusao, propriedades ACID vs CAP, lazy evaluation de RDDs do Spark e etapas do KDD.